

「转载 / 镜像虚假独立来源」修复与新主题自检报告

research-agent · 确定性置信引擎 · 来源身份归一落地

范围：不改动 `extract_evidence` 核心硬阈值计分；只改“来源身份识别”与观测。落地口径：按决策 板①不启用轻改写近重复合并、板②未知主机默认分维持 0.5。验证：全量回归 + eval 语料 + 新主题盲测自检。

一、背景与问题

确定性置信计分以“不同来源（URL）”为交叉验证基准。原 `_url_key` 只返回 `url` 去 `#fragment`：同一份正文被 N 个不同域名转载/镜像时，会被当成 N 个“独立来源”。在 `n_total ≥ 3` 且无分歧 → `high` 的规则下，一堆低可信镜像站即可把单一事实刷成 `high` 置信——这正是“虚假独立来源”漏洞。

核心论断：真正的交叉验证应数独立编辑来源原点(origin)，而非裸 URL。修法是在来源去重/计数这一层做 origin 折叠，完全不动计分阈值。

二、落地范围与决策口径

维度	落地内容	是否碰核心计分
URL 归一	<code>_canonical_url</code> ：去 <code>#fragment</code> 、剔 <code>utm_*/spm</code> 等追踪参数、去 <code>www./m.</code> 前导、查询参数重排	否
逐字镜像折叠	<code>_content_fingerprint</code> 精确整段指纹 → 同指纹的跨站正文并为一 origin（零误伤）	否
origin 接入	<code>_assign_origins</code> 并查集折叠， <code>doc.origin_id</code> 接入 <code>_extract_claims/_claims_to_buckets</code> 去重计数	否
轻改写转载	板①：近重复(n-gram)合并默认不启用，逐字指纹未命中即保持独立来源	否
域名可信度	板②：未知主机默认分维持 0.5，不做额外降权	输入层维持
观测/调试	<code>origin_groups_debug</code> / <code>evidence_debug</code> ：展示谁折叠成谁、collapsed 计数	纯新增
回退开关	<code>ANALYZER_ORIGIN_MERGE=0</code> 一键退回“按原始 URL 计数”	—

决策记录：板①轻改写转载场景本次不启用可信度门控（近重复合并默认关闭），留待观察线上数据再评估是否放开；板②未知主机默认分维持 0.5、本次不调整为 0.42。据此实现已收敛为“完整版但仅折叠逐字镜像”。

三、端到端效果复现（攻击→拦截）

用军工新主题通稿构造“6~10 家低可信镜像站逐字转载”的极端攻击：

场景	修复前	修复后
10 篇同通稿原样镜像（不同低可信域名）	判 high · n_sources≈10	折叠为 1 origin → low · n_sources=1
逐字镜像组最高可取可信度	—	取组内最优代表，不因镜像数量虚高
独立原创长文（智算新主题）	—	保持独立，不误并

四、评估与回归结果

4.1 既有回归（全部通过）

测试	通过/失败	覆盖
test_confidence_scoring	8 / 0	置信分级核心（3 独立→high、分歧→medium、同 URL→low 等）
test_extract_multivalue	8 / 0	P0 一句多值抽取重构
test_fresh_data	14 / 0	换数据验证（舍入噪声、量纲、真实分歧）
test_mirror_origins	8 / 0	转载/镜像回归（逐字折叠、独立不误并、URL 变体、开关回退）
test_near_synonyms	6 / 0	P2 近义归一
test_year_and_recency	8 / 0	P1 年份口径 + 时效

4.2 eval 跨领域语料（100%）

主张级命中 87 / 87 · 句子级全对（含指标与主体）79 / 79 —— 抽取/指标引擎无回归。

五、新主题盲测自检（如实汇报）

引入 16 个既有语料与测试均未覆盖的新领域（军工、航天卫星、冷链、宠物经济、数据中心、院线票房、医美、露营、跨境电商、特种钢、在线问诊、黄金珠宝、储能出货、运动鞋服、考研、预包装食品），对主张抽取做盲测。结果：

指标	结果
主张级命中（数值+年份）	15 / 16
句子级全对（+指标名+主体）	12 / 16
镜像复验 · 军工 6 家逐字镜像 → 折叠	通过 (origin=1, low)
镜像复验 · 智算 3 独立长文 → 不误并	通过 (origin=3)

备注：上表 15/16 含“数值已抽出但指标名/主体未完全符合我给的期望标签”的情形，其中 4 处详见表下——多数为指标归一或主体粒度差异，非漏抽。

5.1 未命中 / 不一致明细

句	期望	实际	性质判断
全国智算中心总算力 2025 年预计超过 300EFLOPS。	总算力 300EFLOPS	未抽到（得空）	真短板：数字/单位引擎未收录 EFLOPS/TOPS/PFLOP 等英文算力单位，整句漏抽。属既有抽取引擎对新领域的覆盖盲区，与镜像修复无关。
2024 年国庆档电影总票房约 28 亿元。	总票房	抽到 28 亿元，归为“规模”	指标归一差异：总票房 被归一进 规模。值对、标签偏宽。
2024 年黄金珠宝消费额同比增长了 18%。	黄金珠宝·增长率	抽到 18%(增长率)，主体为空	复合适体“黄金珠宝”未切出主体。主体粒度盲区。
2025 年考研报名人数为 388 万人。	报名人数 388 万	抽到 388 万人，归“规模”，主体吞过长	指标归一 + 主体切分偏粗：报名人数 未独立成指标、主体未收窄到“考研”。

诚实结论：新主题盲测暴露的是既有抽取引擎的普适性边界（英文算力单位未收录、个别量纲词未归一、复合适体切分），非本次转载镜像修复引入的回归。镜像/独立源两项复验在新主题下均通过，说明“来源归一”修复对任意主题成立。

六、局限与后续（如实）

- **只拦“逐字”镜像：**本轮按板①不启用近重复合并，换词/截断的转载仍会按独立来源计；若线上观测到此类刷量，可复用在 `_assign_origins` 预留处开启 n-gram 近重复 + 可信度门控。
- **英文算力单位盲区：**`EFLOPS / TOPS / PFLOP` 未入数字正则/单位表，含其的量化主张被漏抽，建议补入 `_NUM_RE` 与单位解析。
- **个别量纲/复合适体：**`总票房/报名人数/黄金珠宝` 等归一与主体切分偏粗，属指标归一词典/结构切分可扩展点。
- **主语跨桶：**镜像组内不同 copy 可能被切到不同 subject 标签，但来源数已被折叠，不影响防刷。

一句话结论：来源归一方案可行、低侵入、可回退，逐字镜像刷 High 已在多主题下复验为被正确拦截；新主题盲测所暴露的是抽取引擎的独立普适性盲区，非镜像修复引入，可另行迭代。