

补短板四阶段落地·全量对比评测报告

research-agent 抽取引擎 · 数值召回基线 84% → 97% · 实测可复核



召回口径：真实检索盲测 61 个期望数值（原文明写、逐字核对），跨 8 领域。

一、执行结果摘要

阶段	内容	召回	改动核心	回归
基线	镜像/来源归一修复后稳定态	51/61 = 84%	—	52 全绿
阶段1·簇C	数字错拆止血 + 电学量值就近错配	52/61 = 85%	<code>_numeric_tokens</code> 、 <code>_COUNT_UNIT_RE</code>	52 全绿
阶段2·簇B	句尾数值主体还原（多主体分键）	55/61 = 90%	<code>_subject_for</code> 、新增 <code>_tail_level_subject</code>	67 全绿
阶段3·簇A	条件式放开句内去重（实质不同值并存）	59/61 = 97%	<code>best_by_ind</code> 聚合逻辑	67 全绿

二、阶段细节与修复点

阶段1·簇C：底层止血（数字错拆 + 就近错配）

缺陷	根因	修复	效果
月份/半季数字被当主张	“7月”的 7、“H1/Q2”的 1/2 被 <code>_NUM_RE</code> 当独立数值 token，误占 (指标,年份) 键、顶掉真量值	<code>_numeric_tokens</code> 剔除：后跟“月”的整数字、前导 H/S/Q 字母的标记数字 (iPhone15/A100 型号不受影响)	123.6GWh 不再被 H1 的 1 挤掉
量值就近错绑成比率	GWh/GW/MWh 等能量功率单位不在水平量判定表中 → 219.2GWh 被当非水平量，就近错绑成“同比增长/增长率”	<code>_COUNT_UNIT_RE</code> 补全 GWh/MWh/kWh/GW/MW/W/千瓦等水平量单位	量值不再被错绑比率词

阶段2·簇B：句尾数值主体还原

缺陷：_subject_for 依赖“年份/量纲锚点”切主体。对“实体主体+虚词+数值”的句尾结构（无锚点）切不出，回退整句 → 不同主体的值撞同一脏主题键、被去重顶掉。

句式	修复前主题	修复后主题
新能源约104万辆	8月国内狭义乘用车零售158万辆（脏，与158万撞键）	新能源
其中燃油车只剩约54万辆	158万辆同比下滑21.7%，其（整句脏）	燃油车
宁德时代以125GWh位居第一	储能电池（脏）	宁德时代
排名第二的亿纬锂能(48GWh)	储能电池（脏）	亿纬锂能

实现新增 _tail_level_subject，仅对水平量值（非 %）触发；指标词尾/纯时间/纯虚词黑名单拦截；承前省略（较去年同期/比X）返回空不产假主题。

阶段3·簇A：条件式放开句内去重

将 best_by_ind 的“每 (指标,主题,年份) 只留最近一条”改为：同一键下，新值与已保留者 _values_close 为假（数值真不同）→ 追加保留；数值近似（口径噪声如 12.0亿 vs 12.1亿）仍只留一条。叠加单句条数上限 _CLAUSE_MAX_CLAIMS = 8。

句式	阶段2前	阶段3后
环比增35%；同比更是高达104%	只出 35%	35% + 104%
燃油车54万辆…降幅超过40%	21.7% 顶掉 40%	21.7% + 40%
环比分别下降6.8%和8%	只出 6.8%	6.8% + 8%
12.48GW 较去年同期 14.36GW	只出 12.48GW	两条并存

三、精确率 / 膨胀监控（无代价的纯增益）

- 膨胀探针：9 句单主张探针（每段本只应抽 1-2 条），四阶段全程 0 多抽——条件放开没有让单主张句多出无期望对应的假主张。
- 单句上限：病态超长多值句（10 个“达X万台”）被截断到 8 条，不撑爆上下文。
- 句子级全对：跨领域语料（79 句/87 主张）四阶段均 100%，主体/指标绑定未因改动退化。

四、置信等级稳定性（防“刷 High”地基未被破坏）

场景	置信输出	结论
单来源同句抽出 3 个不同值(100/200/300亿美元)	low / 0.34 ×3	high 按来源数而非主张数计，刷多值推不高
3 个独立来源给出同一值	high / 0.95	多源一致照常判高
同主题 12.0亿 vs 12.1亿	只留 1 条	口径噪声仍去重，不放大数值膨胀

五、分领域最终召回

领域	基线	最终	领域	基线	最终
车	16/20	20/20	OLED	4/4	4/4
锂电	11/14	13/14	机器人	3/3	3/3
光伏	8/10	9/10	AI芯片	2/2	2/2
半导体	3/4	4/4	咖啡	4/4	4/4

六、剩余 2 处漏抽（可接受的语义深度遗留）

漏抽	原因	性质
219.2GWh（2026年 H1出货量）	整句指标被句中后段“市场份额”劫持，分句级出货量量值无指标可用被丢弃	需“分句级指标选择”，下轮方向
8.68GW（5月单月新增装机）	“1-5月累计59.59GW” vs “5月单月仅8.68GW” 的 累计/单月语义层级	需“时间区间/口径语义”，下轮方向

这两处均已定位到具体机制，但属语义层理解（分句指标归属、累计 vs 单月口径），非本阶段机械规则可直接收敛，已如实记录供下轮。

七、代码变更清单（git: 6751a0d → 3d7b9cc）

文件	改动	开关
research_agent/analyzer.py	补单位表；杂音过滤；新增 _tail_level_subject ； best_by_ind 条件聚合 + 条数上限	ANALYZER_KEEP_DISTINCT=0 可关簇A回退
	阶段1/2 专项回归 15 项（新增）	—

tests/ test_tail_numeric_subject.py		
tests/eval_stage_compare.py	阶段4 对比评测脚本（新增）	—

报告基于真实检索盲测（real_scale_blind.py, 61 期望值/8 领域）+ 跨领域语料 eval + 67 项回归实测生成。完整可复现：git log 6751a0d..HEAD；四阶段逐 commit 复跑盲测得到 84/85/90/97%。